INSTITUTO TECNOLÓGICO SUPERIOR DE LA
REGIÓN DE LOS LLANOS

Materia: CIBERFÍSICA E INTELIGENCIA ARTIFICIAL APLICADA

Actividad: U2A4. PRÁCTICA. Splits reproducibles de un dataset abierto

Nombre:

Carlos Diego Dominguez López - 21030006

Docente: Osbaldo Aragón Banderas

Fecha: 14 / 04 /2026

TECNM
TECNOLÓGICO NACIONAL DE MÉXICO

INDICE

¿Qué son los Splits de un Dataset? 1

¿Por qué son importantes? 1

Nota Técnica 1

Paso 1: Cargar el dataset 1

Paso 2: Preparar los datos 2

Paso 3: Dividir el dataset 2

Paso 4: Guardar los resultados 3

Graficas de los Datos Train/Test 3

Conclusión 4

¿Qué son los Splits de un Dataset?

Los splits de un dataset consisten en separar la información disponible en varias partes para usarlas con diferentes propósitos al entrenar un modelo de inteligencia artificial. Normalmente se separa en datos para entrenamiento, validación y prueba, de modo que el modelo no use toda la información al mismo tiempo y se pueda evaluar correctamente.

¿Por qué son importantes?

Son importantes porque permiten entrenar y evaluar el modelo de forma más confiable. Al usar datos distintos para entrenar y para probar, se evita que el modelo solo memorice la información y en su lugar aprenda patrones reales. Esto ayuda a saber si el modelo funcionará bien con datos nuevos en situaciones reales, asegurando resultados más precisos y útiles.

Nota Técnica

Paso 1: Cargar el dataset

Lo primero que se hizo fue importar las herramientas necesarias. **pandas** se usa para manejar datos en forma de tablas, **load_iris** para cargar el dataset y **train_test_split** para dividir los datos.

```
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split

iris = load_iris()
```

Figura 1. Importación de librerías y carga del dataset

Paso 2: Preparar los datos

El dataset se convierte en una tabla (DataFrame) y se agrega la columna target, que representa la clase de cada flor. Esto facilita trabajar con los datos para su posterior división y análisis.

```
df = pd.DataFrame(iris.data, columns=iris.feature_names)
df['target'] = iris.target
```

Figura 2. Conversión del dataset a DataFrame

Paso 3: Dividir el dataset

Se realiza la partición usando una proporción de 80% para entrenamiento y 20% para prueba. La semilla utilizada es 42, lo que asegura que la división sea siempre la misma.

```
train_df, test_df = train_test_split(df, test_size=0.2, random_state=42)
```

Figura 3. Partición y Semilla utilizada

El criterio de división aplicado es aleatorio, lo que significa que los datos se mezclan antes de separarse para evitar sesgos y mantener una distribución representativa.

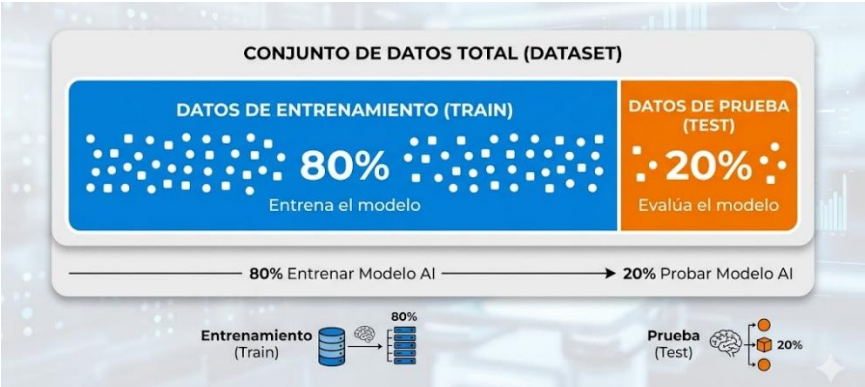

Figura 4. División del Dataset en una Proporción 80/20

Paso 4: Guardar los resultados

Los datos ya divididos se guardan en dos archivos: train.csv y test.csv. Esto permite reutilizar los conjuntos sin necesidad de repetir todo el proceso.

```
train_df.to_csv('train.csv', index=False)
test_df.to_csv('test.csv', index=False)

print("Archivos generados: train.csv y test.csv")
```

Figura 5. Importación de archivos CSV

Graficas de los Datos Train/Test

La gráfica del conjunto de entrenamiento muestra la distribución de los datos que el modelo usará para aprender. En este caso, al tratarse del **Iris dataset**, cada punto representa una flor y su posición depende de dos características (por ejemplo, largo y ancho del sépalo). Los diferentes colores indican las clases.

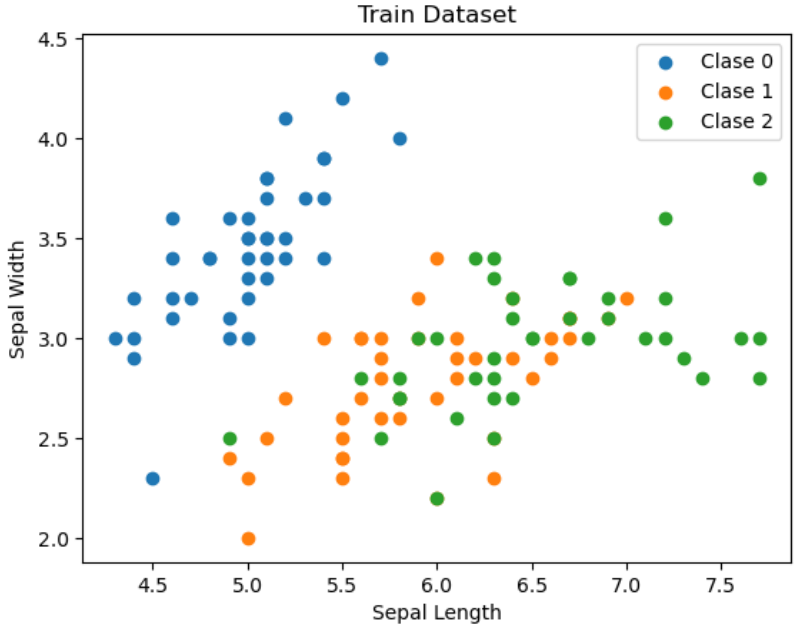

Figura 6. Grafica del conjunto de entrenamiento

La gráfica del conjunto de prueba muestra una porción más pequeña de datos que el modelo no ha visto durante el entrenamiento. Aunque hay menos puntos, se mantiene una distribución similar a la del conjunto de entrenamiento, lo cual es importante para evaluar el modelo de forma justa.

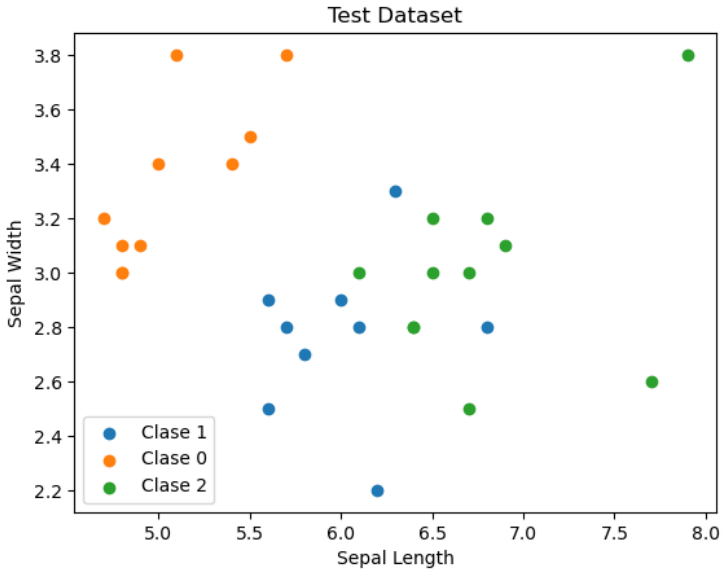

Figura 7. Grafica del conjunto de prueba

Conclusión

En conclusión, dividir un dataset como el **Iris dataset** en conjuntos de entrenamiento y prueba es fundamental para desarrollar modelos de inteligencia artificial confiables. Este proceso permite que el modelo aprenda con una parte de los datos y luego sea evaluado con información nueva, asegurando que realmente entienda los patrones y no solo memorice. Además, el uso de una proporción adecuada, una semilla fija y una división aleatoria garantiza resultados consistentes y representativos, lo que facilita un análisis más preciso y útil.